UNIVERSIDAD POLITÉCNICA DE MADRID
ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INFORMÁTICOS

APRENDIZAJE AUTOMÁTICO I

CLASIFICACIÓN DE CÁNCER CON APRENDIZAJE SUPERVISADO

3º Grado Ciencia de Datos e Inteligencia Artificial
10/12/2025

1. INTRODUCCIÓN:

La detección temprana y la correcta clasificación de tumores mamarios es un aspecto clave del diagnóstico clínico, ya que permite diferenciar lesiones benignas de tumores malignos que requieren intervención inmediata. En este contexto, las técnicas de Aprendizaje Automático Supervisado resultan especialmente útiles, pues permiten construir modelos capaces de aprender patrones complejos a partir de datos reales.

En este proyecto se utiliza el dataset *Cancer_Data.csv*, que contiene 30 variables numéricas procedentes del análisis morfológico de núcleos celulares obtenidos mediante imágenes digitales (características como *radius*, *texture*, *perimeter* o *concavity*). Estas medidas cuantifican propiedades relevantes de la estructura tumoral y capturan señales indicativas de malignidad.

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean
0	842302	M	17.99	10.38	122.80	1001.0
1	842517	M	20.57	17.77	132.90	1326.0
2	84300903	M	19.69	21.25	130.00	1203.0
3	84348301	M	11.42	20.38	77.58	386.1
4	84358402	M	20.29	14.34	135.10	1297.0

5 rows × 33 columns

El objetivo es predecir la variable *diagnosis* (0 = benigno, 1 = maligno) y comparar el rendimiento de cuatro algoritmos supervisados: Regresión Logística, Árbol de Decisión, K-Vecinos más Cercanos y Máquinas de Soporte Vectorial. El estudio incluye la separación en entrenamiento y test, la validación cruzada con ajuste de hiperparámetros mediante *GridSearchCV*, la comparación de métricas y la interpretación del árbol de decisión.

Dado el carácter clínico del problema, la evaluación no puede basarse únicamente en la *accuracy*. Es fundamental considerar el coste diferencial de los errores, especialmente los falsos negativos, que corresponden a clasificar como benigno un tumor maligno. Por ello, métricas como el *recall* y la *precision* de la clase maligna, junto con el análisis de las matrices de confusión, adquieren un papel central en la valoración final de los modelos.

2. DESCRIPCIÓN DEL PROBLEMA :

Nos enfrentamos a un problema de clasificación binaria supervisada, cuyo objetivo es determinar si un tumor es benigno (0) o maligno (1) a partir de 30 variables cuantitativas derivadas de imágenes digitales de tejido mamario. Estas características describen propiedades morfológicas clave de los núcleos tumorales (tamaño, textura, irregularidad o concavidad) que suelen diferenciar tumores benignos de malignos con alta precisión.

La salida esperada es una etiqueta binaria, y el modelo debe aprender la frontera de decisión que mejor separa ambos tipos de tumores. Sin embargo, en el ámbito clínico los errores tienen un valor desigual:

- Falso positivo (FP): El tumor es Benigno(0), pero el modelo predice Maligno(1).
- Falso negativo (FN): El tumor es Maligno (1), pero el modelo predice Benigno(0). Este es el error de mayor coste y por tanto el más delicado.

Hemos puesto especial énfasis en el análisis del falso negativo, como se verá en el apartado de metodología, pero esto es debido a su gravedad. En su evaluación no nos limitamos al Accuracy Global si no que usamos otras métricas como Recall o precisión.

Recall mide la fracción de tumores malignos que el modelo identifica correctamente, es decir, reduce el número de tumores malignos que se “pierden”.
Precisión de la clase positiva mide todas las predicciones “maligno” que realmente lo son. Una precisión alta evita demasiados falsos positivos.

En resumen, el problema se formula no solo como una tarea de clasificación, sino como una evaluación clínica asistida, donde la prioridad es minimizar los falsos negativos sin perder un rendimiento global sólido. Esto guía la elección de métricas, modelos y criterios de validación a lo largo del estudio.

3. METODOLOGÍA

3.1 Preparación y limpieza del Dataset

El primer paso de la metodología consiste en garantizar que los datos estén en un formato adecuado para su posterior análisis y modelado. Para ello, se realizó un proceso de limpieza estructurado sobre el dataset original Cancer_Data.csv. Las operaciones efectuadas fueron:

1. **Creación de una copia del dataset original**, con el fin de preservar los datos brutos y evitar modificaciones accidentales.
2. **Eliminación de la columna vacía Unnamed: 32**, presente en algunas versiones del conjunto de datos pero sin información útil.
3. **Eliminación de la columna id**, que actúa únicamente como identificador y no aporta valor predictivo.
4. **Conversión de la variable objetivo diagnosis**, fue transformada de un formato categórico a uno numérico binario, requisito indispensable para la implementación de algoritmos de clasificación como Scikit-Learn:
   $B \rightarrow 0$ (benigno) y $M \rightarrow 1$ (maligno)
5. **Gestión de valores faltantes (NaN)**, Se realizó una verificación exhaustiva y se procedió a la eliminación de cualquier fila que contuviera valores faltantes. Esta acción es especialmente crítica para modelos paramétricos como la Regresión Logística, que no manejan intrínsecamente los valores NaN y requieren conjuntos de datos completos para una estimación de parámetros precisa.
6. **Conversión de Tipo de Datos**, se aseguró que todas las columnas predictivas fueran de tipo numérico (float64). Cualquier valor que no pudiera ser convertido se trataría como NaN y se eliminaría en el paso de gestión de nulos.

Tras estas operaciones, el conjunto de datos resultante (df_clean) contiene 569 observaciones y 31 columnas, totalmente preparado para el análisis exploratorio y la fase de modelado.

3.2 Análisis Exploratorio de Datos

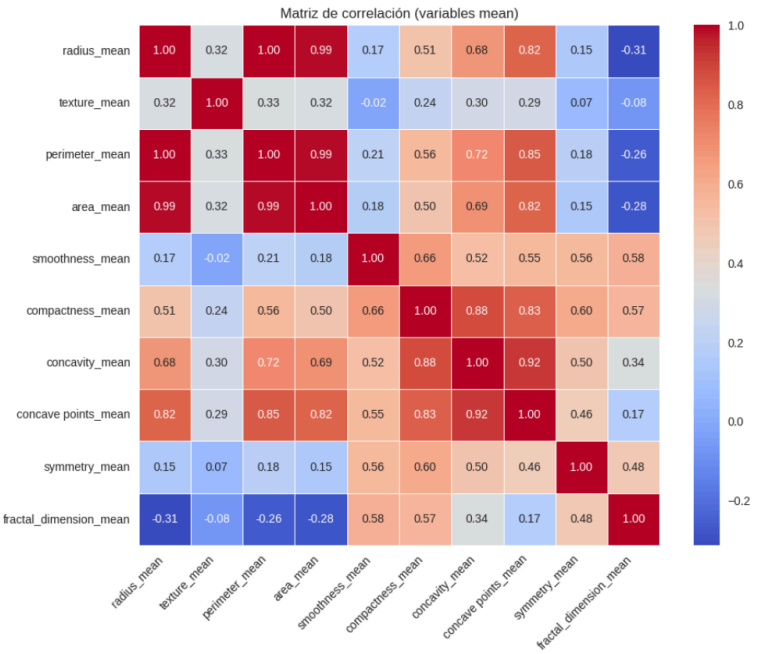
Se generaron **histogramas** para todas las variables numéricas con el objetivo de:

- Identificar la forma de las distribuciones.
- Detectar asimetrías pronunciadas (muchas variables muestran sesgo hacia la derecha).
- Visibilizar la presencia de posibles valores extremos.
- Observar si las variables presentan distintos rangos o magnitudes.

En los histogramas, se observó que una gran parte de las variables relacionadas con el tamaño y la geometría como radius_mean o area_mean, presentan sesgo positivo, es decir, hay muy pocos tumores muy grandes y los pocos que hay son malignos (tendencia)

Los boxplots mostraron una fuerte disparidad de escalas entre las características: mientras variables como area_mean toman valores en el orden de los miles, otras como fractal_dimension_mean se sitúan en centésimas. Además, se identificó una cantidad considerable de valores atípicos asociados a tumores de tamaño o geometría inusualmente alta. Estas observaciones justifican la aplicación de un escalado estándar (StandardScaler) antes del entrenamiento, ya que muchos de los modelos utilizados (K-NN, SVM y Regresión Logística) son sensibles a la magnitud de los features y a la presencia de outliers. El escalado garantiza que todas las variables contribuyan de manera equilibrada a la distancia y a la optimización del modelo.

En cuanto a la **matriz de correlació**n, esta se calculó unicamente con la medidas promedio de las variables del tumor. En ella se evidenció una alta multicolinealidad dentro del grupo de variables que definen el tamaño, donde loa coeficientes de correlación de Pearson se acercan a 1.00, eso mismo lo vimos con los histogramas anteriormente.
Esto podría hacer que los modelos lineales sean menos estables.



Para evaluar como cada variable separa los tumores benignos de los malignos , utilizamos histogramas por clase y un pairplot:

-Las visualizaciones de los histogramas por clase revelan que las variables como radius_mean, perimetrer_mean y area_mean aparecen desplazadas hacia valores más altos en la clase maligna que en la benigna, como vimos hasta ahora. Por lo que estas variables aportan mucha información para distinguir entre las clases y hay una diferencia real entre ellas.



-El **Pairplot** confirma esta separabilidad al mostrar nubes de puntos bien diferenciadas entre las dos clases en múltiples combinaciones de variables, especialmente en aquellas relacionadas con la compacidad, concavidad y morfología del tumor. La clara separación visual nos muestra que el problema es en gran medida linealmente separable, de modo que incluso modelos lineales pueden aproximar adecuadamente la frontera de decisión. En cambio, se espera que los modelos supervisados alcancen un rendimiento elevado, lo que comprobaremos a continuación.

3.3 Separación de Datos y Preprocesamiento:

3.3.1. División Entrenamiento/Test

Primero divismos nuestros datos en test y train con el objetivo de evaluar el modelo de forma justa. Para ello el 70% del dataset fue para el entrenamiento, con un total de 398 muestras para que así el modelo aprenda patrones, mientras que el 30% restante para prueba , con un total de 171 muestras para evaluar el rendimiento real. Esta distribución nos permite tener suficientes datos para entrenar y también tener una parte representativa para evaluar sin ningun tipo de sesgo.

Una cosa que añadimos en esta parte de entrenamiento es la estratificación, añadimos una línea *stratify = y* . Esto obliga a nuestra parte de entrenamiento a mantener la misma proporción de benignos y malignos en ambos conjuntos. Si el dataset original tiene 62% benignos y un 38% malignos entonces el train tendrá esa misma proporción y por tanto el test también.
Sin esto, el modelo podría aprender mal y la evaluación sería injusta.

3.3.2. Estandarización y Pipelines

El preprocesamiento es crítico porque los modelos no funcionan bien si las variables no están en una misma escala, ya que la diferencia de valores sería incongruente y unas dominarías sobre otras, por ello es necesario estandarizar las variables, en nuestro caso, empleamos StandardScaler, que convierte cada variable con media 0 y desviación estándar 1. Esto es esencial para los modelos basados en distancia, como son K-NN y SVM.

Por otro lado los Pipeline garantizan que el escalado se aprenda solo con X_train y que después este mismo escalado se aplique a X _ test, por su encapsulamiento. Esto evita que la información del test se filtre al entrenamiento y haga que el rendimiento parezca mejor de lo que realmente es.

3.4. Optimización de Modelos con GridSearchCV

Para la fase de modelado se empleó **GridSearchCV**, una técnica que combina la búsqueda exhaustiva de hiperparámetros con validación cruzada. Su objetivo es seleccionar, para cada algoritmo, la configuración que ofrece el mejor rendimiento de manera estable y generalizable, evitando que una única partición del conjunto de datos condicione la calidad del modelo.

En lugar de evaluar el rendimiento con un simple train/test, GridSearchCV divide los datos en varias particiones (folds) y prueba cada combinación de hiperparámetros en todas ellas. Esto aporta ventajas clave:

- Reduce la varianza asociada a una única división de los datos.
- Proporciona una estimación más sólida del rendimiento real.
- Permite comparar modelos muy diferentes bajo condiciones idénticas.

Esto es especialmente importante en datasets moderados como el nuestro (569 observaciones), donde una partición concreta puede influir notablemente en los resultados.

En un principio, probamos a entrenar el modelo 10 veces (cv = 10), pero el proceso resultaba demasiado lento. Probamos entonces con cv = 5 y observamos que la estabilidad de los resultados era prácticamente idéntica a la obtenida con cv = 10, pero con un coste computacional muy inferior. Por ello, cv = 5 representó la mejor relación entre fiabilidad estadística y eficiencia.

Durante la optimización, GridSearchCV utilizamos Accuracy como métrica principal. Esta elección es coherente con lo observado en el análisis exploratorio de datos: las variables del dataset separan con claridad las clases benigno y maligno, (como vimos anteriormente en el Pairplot) por lo que la probabilidad de acierto es una medida representativa del rendimiento.

Modelos Evaluados: En este proyecto se han evaluado cuatro algoritmos de naturaleza muy distinta con el fin de determinar cuál ofrece el mejor rendimiento en la clasificación de tumores benignos y malignos. Cada uno de ellos aprende patrones de manera diferente, maneja la complejidad de formas distintas y responde de forma particular a los hiperparámetros que optimizamos con GridSearchCV. Estos son : Regresión Logística, SVM, K-NN y los Árboles de decisión.

4. RESULTADOS

En esta sección se analizan los resultados obtenidos tras la evaluación de los modelos optimizados mediante GridSearchCV. Para ello se interpretan cuatro tipos de gráficos: matrices de confusión, curvas ROC, distribución de probabilidades y representación del árbol de decisión.

4.1 Calibración

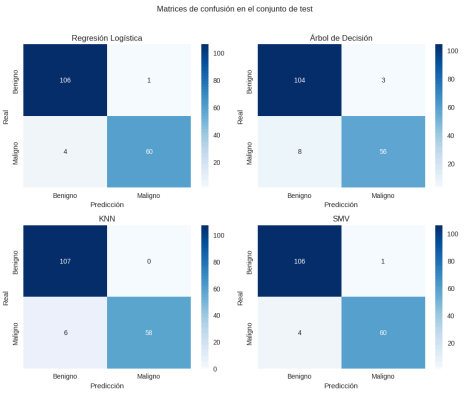
En cuanto a la calibración de probabilidades, los modelos muestran comportamientos distintos: la Regresión Logística se encuentra muy bien calibrada, con probabilidades que reflejan fielmente la frecuencia real de los eventos, especialmente en rangos intermedios, lo que confirma su naturaleza probabilística lineal; el Árbol de Decisión tiende a predecir probabilidades extremas y poco fiables, evidenciando su inestabilidad y sobreajuste; K-NN presenta saltos bruscos y desviaciones importantes, reflejando que sus probabilidades derivan de la proporción de vecinos y no de una estimación probabilística real; finalmente, el SVM con kernel RBF también muestra desviaciones notables en rangos bajos, indicando que aunque clasifica muy bien (alto AUC y bajos falsos negativos), sus scores no son directamente interpretables como probabilidades fiables.

4.2 Matrices de Confusión y Análisis del Error

Los primeros gráficos analizados fueron las matrices de confusión del conjunto de test y el diagrama comparativo de errores (Falsos Positivos y Falsos Negativos).

Los resultados muestran un patrón claro:

- Regresión Logística (RL) y SVM alcanzan el mejor desempeño, con solo 4 FN cada uno.
- K-NN se sitúa como el segundo mejor modelo, con 6 FN.
- Árbol de Decisión, en cambio, presenta la peor cifra, con 10 FN, confirmando su menor estabilidad.

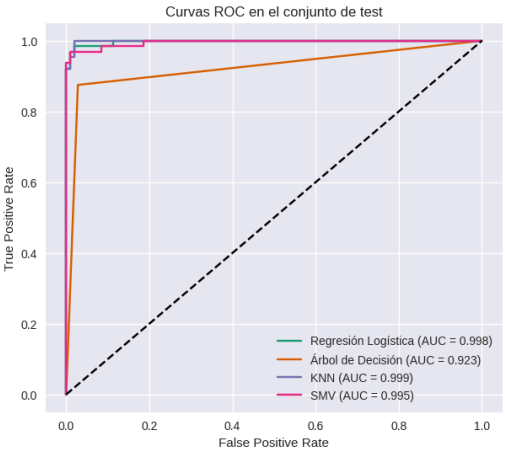


El gráfico de barras de errores refuerza esta tendencia:

- KNN y SVM destacan por tener los Falsos Positivos (FP) más bajos (0 y 1 respectivamente), lo que implica que apenas generan alarmas innecesarias.
- Sin embargo, desde un punto de vista clínico, la prioridad es reducir al máximo los FN: en este sentido, RL y SVM vuelven a ser los más robustos, seguidos de K-NN, y claramente por encima del Árbol de Decisión.

4.3 Curvas ROC y AUC

Las Curvas ROC permiten evaluar la capacidad discriminativa de cada modelo sin depender de un umbral fijo. El Área Bajo la Curva (AUC) es especialmente informativa en problemas con clases muy separables, como reveló el análisis exploratorio.

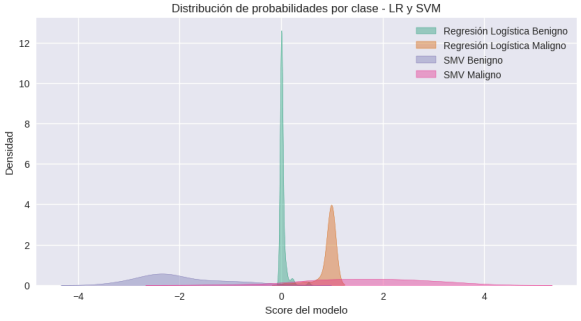


- KNN, RL y SVM obtienen valores prácticamente perfectos, lo que confirma que la frontera entre benignos y malignos está bien definida y que estos modelos la capturan eficazmente.
- El **Árbol de Decisión**, por el contrario, se queda muy por debajo. Su menor AUC refleja que el modelo no mantiene un equilibrio adecuado entre sensibilidad y especificidad a distintos umbrales, lo cual es característico de modelos que han sobreajustado patrones locales.

La ROC sostiene, por tanto, la superioridad de los modelos paramétricos / basados en distancia y la menor generalización del Árbol de Decisión.

4.4 Distribución de Probabilidades: RL vs SVM

Se analizó la distribución de probabilidades generada por la Regresión Logística y por SVM, un gráfico especialmente útil porque muestra la confianza y separación interna que realiza

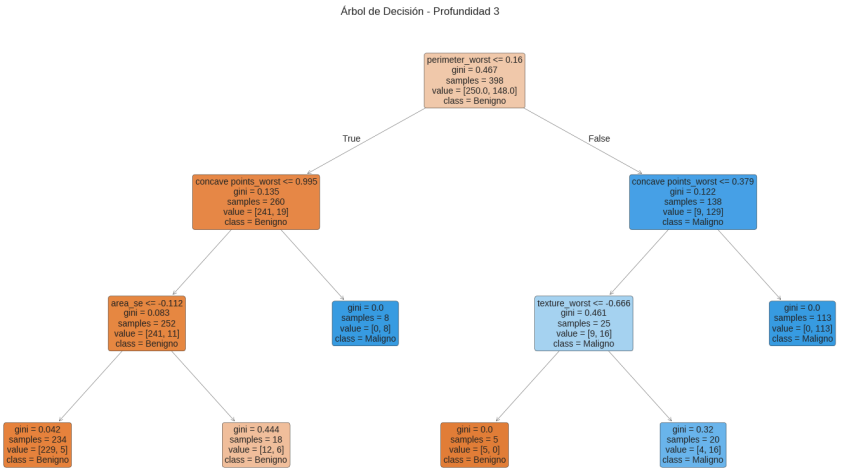


cada clasificador. Los resultados evidencian comportamientos muy diferentes. La Regresión Logística produce distribuciones compactas y claramente bimodales: los casos benignos se concentran cerca del extremo negativo y los malignos en el extremo positivo, con una superposición mínima. Esto refleja una frontera lineal muy estable y acorde con la fuerte separabilidad del dataset. Por el contrario, SVM con kernel RBF genera distribuciones más amplias y dispersas, señal de que el modelo trabaja en un espacio transformado de mayor dimensión y busca fronteras más complejas y curvadas. En conjunto, la Regresión Logística captura la estructura lineal dominante del problema, mientras que SVM modela pequeñas no linealidades en las zonas donde existe solapamiento entre clases.

4.5 Análisis del Árbol de Decisión (Profundidad 3)

Aunque el Árbol de Decisión óptimo encontrado por GridSearchCV tenía profundidad no limitada (max_depth = None), se representó gráficamente una versión podada a profundidad 3 para facilitar su interpretación. Dos resultados importantes:

Variables más influyentes: Las primeras divisiones se basan en perimeter_worst, concave points_worst y area_se, lo que coincide con el análisis estadístico previo: las características relacionadas con tamaño, concavidad y “peor caso” de la lesión son las más relevantes para distinguir malignidad.



Tendencia al sobreajuste: Incluso con profundidad 3, ya se observan subdivisiones muy específicas, separando grupos pequeños para lograr nodos puros. Este comportamiento anticipa el sobreajuste del modelo completo y explica su bajo rendimiento en test: el árbol reproduce patrones locales en lugar de capturar relaciones generales y estables.

5. DISCUSIONES

5.1 Implicaciones de Calibración

El análisis de las Curvas de Calibración permite evaluar la fiabilidad de las probabilidades predichas más allá de la precisión. Este estudio confirma que la Regresión Logística es el modelo mejor calibrado, por lo que sus probabilidades resultan las más fiables para la toma de decisiones clínicas. En cambio, K-NN y SVM, al basarse en distancias y márgenes, generan probabilidades mal calibradas; sus salidas deben interpretarse con cautela y utilizarse principalmente por su alta capacidad de discriminación (AUC), no por el valor numérico de la probabilidad predicha.

5.2 Regresión Logística

La Regresión Logística es un modelo estadístico lineal diseñado para problemas de clasificación binaria, cuyo objetivo es estimar la probabilidad de pertenecer a una de las dos clases. A diferencia de la regresión lineal clásica, utiliza la función logística (sigmoide), que transforma cualquier combinación lineal de las variables numéricas en valores entre 0 y 1. Es decir, busca un hiperplano que separe las dos clases maximizando la probabilidad de clasificación correcta.

Es relevante en relación con nuestro dataset ya que permite identificar la contribución relativa de cada variable y funciona especialmente bien cuando las clases son separables (como bien vimos, la frontera entre benignos y malignos es continua y suave).

5.3 SVM (Support vector Machine)

Aunque la Regresión Logística se ajustó bien a la frontera principal entre tumores benignos y malignos, el análisis exploratorio mostró que algunas variables de forma (como *compactness*, *concavity* o *symmetry*) presentan patrones más complejos y zonas de solapamiento no lineales. En estos casos, el SVM resulta especialmente adecuado, ya que busca la frontera que maximiza el margen y, con un kernel RBF, puede proyectar los datos a un espacio de mayor dimensión para capturar curvaturas suaves sin perder capacidad de generalización.

El mejor modelo según GridSearchCV (RBF, C = 10, gamma = “scale”) logró precisamente este equilibrio: el kernel capturó las pequeñas no linealidades en las áreas de solapamiento y un C intermedio evitó excesiva rigidez o flexibilidad. Así, el SVM obtuvo una frontera casi lineal donde era suficiente y más adaptativa en zonas ambiguas, lo que explica su alto rendimiento en Accuracy y AUC. Su principal limitación es la falta de calibración: el SVM maximiza la separación entre clases, pero no produce probabilidades reales, sino distancias al hiperplano. Por ello, aunque clasifica muy bien, sus puntuaciones no representan el riesgo clínico de forma directa.

5.4 K-NN (K-Nearest Neighbors)

K-NN nos proporcionó información importante sobre la estructura de nuestro dataset. En primer lugar, el hecho de que la mejor configuración encontrada por GridSearchCV fuese k = 11, con distancia Manhattan (p = 1) . La elección de la ponderación por distancia weights= “distance”) significa que el voto de un vecino más cercano a la nueva muestra tiene más peso o influencia en la clasificación final que el voto de un vecino más lejano dentro del vecindario de k=11. Este ajuste permite que el modelo aproveche la estabilidad que ofrece un vecindario grande (por el k=11 alto), al mismo tiempo que prioriza la información local más relevante, mejorando la precisión.

Después de probar diferentes opciones, que nuestro modelo elegido sea con p = 1 y no con distancia euclidiana, nos da información sobre las muestras, estas no se distribuyen uniformemente en todas las dimensiones como bien sabemos.

En resumen,con K-NN vimos que la separabilidad del problema es fuerte, pero también tenemos limitaciones de los métodos basados estrictamente en distancias cuando existen pequeñas irregularidades o zonas de solapamiento entre clases.

5.5 Árbol de Decisión

Un Un árbol de decisión aprende mediante reglas del tipo “si *concavity_mean* > umbral, predice maligno”, dividiendo el espacio en regiones cada vez más específicas. Esta flexibilidad le permite modelar relaciones no lineales, pero también lo hace muy propenso al sobreajuste, especialmente en un dataset con variables muy correlacionadas y algunos valores extremos. En la optimización, GridSearchCV seleccionó un árbol con *max_depth=None*, que tiende a crecer sin límite y a ajustarse a pequeñas irregularidades pese a restricciones como *min_samples_split* y *min_samples_leaf*. Por ello su rendimiento en validación cruzada (0.94) fue más bajo e inestable respecto a los otros modelos.

Además, las zonas donde las clases se solapan afectan especialmente a los árboles: pequeños cambios en los datos pueden modificar su estructura y generar reglas distintas, aumentando la varianza. En contraste, modelos como SVM o Regresión Logística suavizan la frontera de decisión, lo que les aporta mayor estabilidad y mejor capacidad de generalización.

6. CONCLUSIONES

El trabajo desarrollado demuestra que, tras un preprocesamiento cuidadoso y una optimización rigurosa mediante GridSearchCV, los modelos de clasificación aplicados al dataset de diagnóstico tumoral alcanzan un rendimiento excepcional. El análisis exploratorio reveló que las variables morfológicas del tumor presentan una alta separabilidad entre clases, lo que favorece la eficacia de clasificadores lineales y basados en márgenes.

Esto se confirmó empíricamente: La Regresión Logística logró un 97.08% en el conjunto de test, con muy pocos falsos negativos, lo cual es especialmente relevante desde un punto de vista clínico. SVM con kernel RBF demostró ser un perfecto algoritmo para la separación de clases (logrando un rendimiento predictivo idéntico a RL), gracias a su enfoque en el margen máximo. Sin embargo, dado que no está diseñado para estimar frecuencias sino distancias, no proporcionó resultados probabilísticos fiables (modelo mal calibrado). K-NN también mostró un comportamiento sólido, aunque ligeramente inferior, mientras que el Árbol de Decisión quedó rezagado debido a su mayor tendencia al sobreajuste.

Las métricas adicionales (F1, recall, AUC, matrices de confusión y curvas ROC) corroboraron de forma consistente estos resultados. En conjunto, el estudio evidencia que, con una preparación adecuada del dataset y una evaluación metodológicamente sólida, es posible obtener modelos altamente fiables para apoyar el diagnóstico del cáncer de mama, manteniendo la interpretabilidad y ajustándose al temario y restricciones de la práctica.

7. REFERENCIAS

- Wisconsin Diagnostic Breast Cancer (WDBC) Dataset. UCI Machine Learning Repository.
- Documentación oficial de scikit-learn: https://scikit-learn.org
- Material de moodle (sobre regresión logística, K-NN, SVM, árboles y validación cruzada).