APRENDIZAJE AUTOMÁTICO I

- Clasificación de Cáncer con Aprendizaje Supervisado-



UNIVERSIDAD POLITÉCNICA DE MADRID



ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INFORMÁTICOS

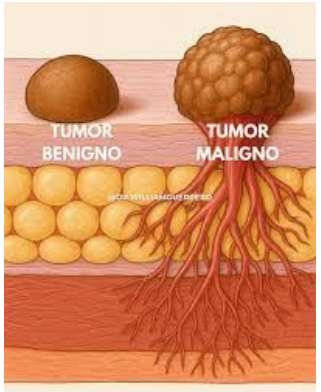
ÍNDICE

1. INTRODUCCIÓN Y DESCRIPCIÓN DEL PROBLEMA
2. METODOLOGÍA
3. RESULTADOS
4. DISCUSIÓN
5. CONCLUSIÓN

1. INTRODUCCIÓN Y DESCRIPCIÓN DEL PROBLEMA

- Dataset: **569 muestras · 30 variables morfológicas**
- Objetivo: **clasificar benigno (0) vs maligno (1)**
- Modelos: **RL · SVM · KNN · Árbol**
- Optimización: **GridSearchCV**
- Error crítico: **falsos negativos**
- Métricas clave: **Accuracy · Recall · AUC**

¿ Qué estamos clasificando?



Características morfológicas → Modelo → Diagnóstico

2. METODOLOGÍA

- Limpieza → eliminar, convertir y transformar columnas y filas
- Análisis Exploratorio → StandardScaler
- Train/Test y Preprocesado → 70% Training y 30% Test
- GridSearchCV → cv = 5, accuracy
- Optimización de modelos→ RL, SVM, KNN, Árbol de Decisión

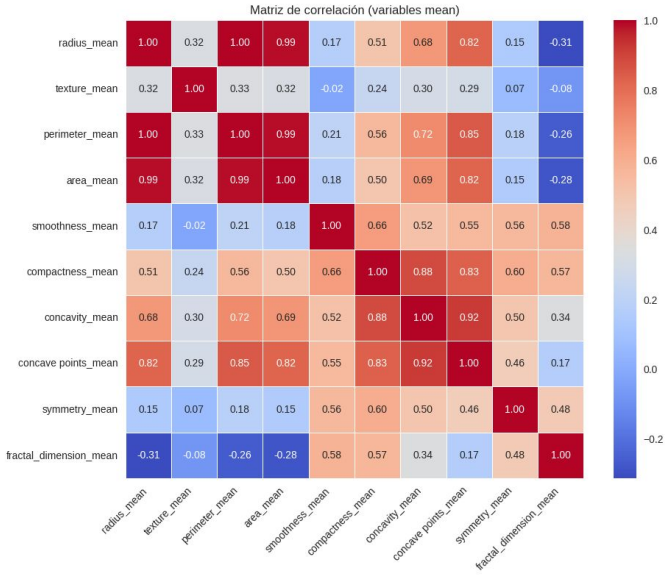
	id	diagnosis
0	842302	M
1	842517	M
2	84300903	M
3	84348301	M
4	84358402	M

5 rows × 33 columns

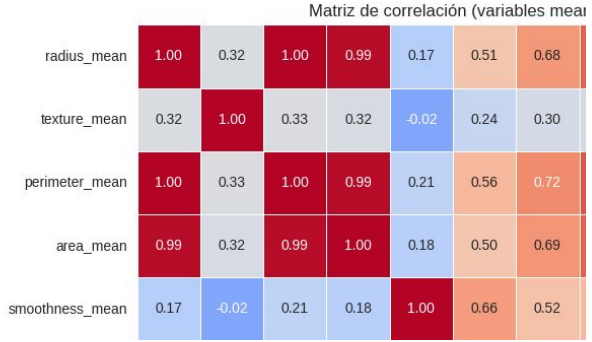
Unnamed: 32
NaN
NaN
NaN
NaN
NaN

```
Dataset limpio
Shape: (569, 31)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 31 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   diagnosis               569 non-null    int64
 1   radius_mean             569 non-null    float64
 2   texture_mean            569 non-null    float64
 3   perimeter_mean          569 non-null    float64
```

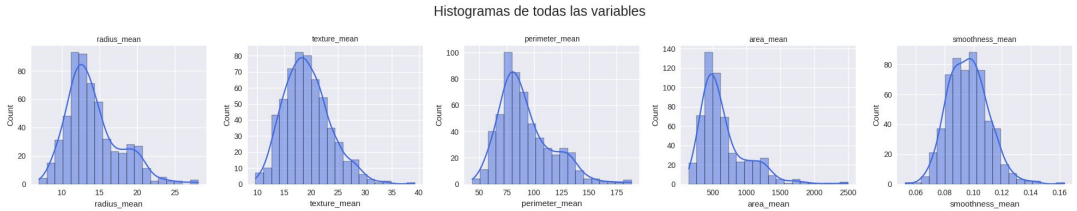
2. METODOLOGÍA





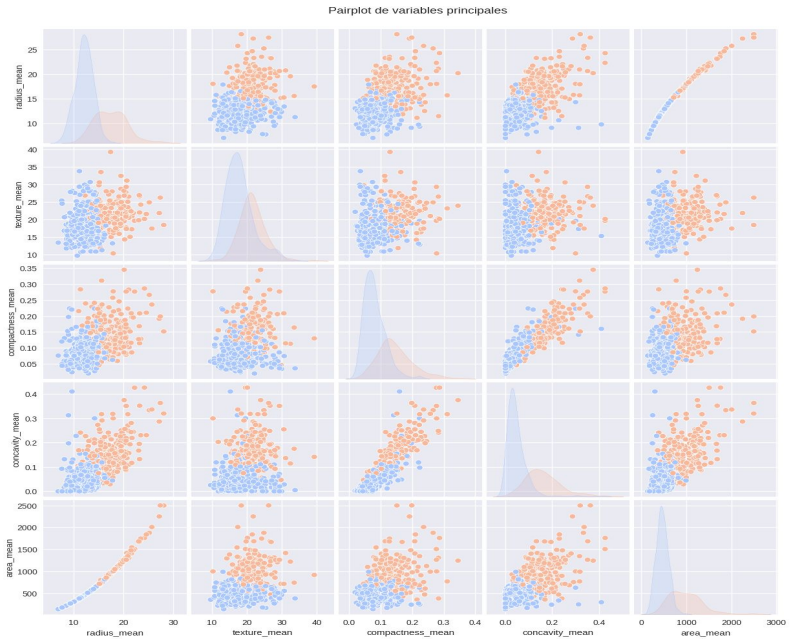


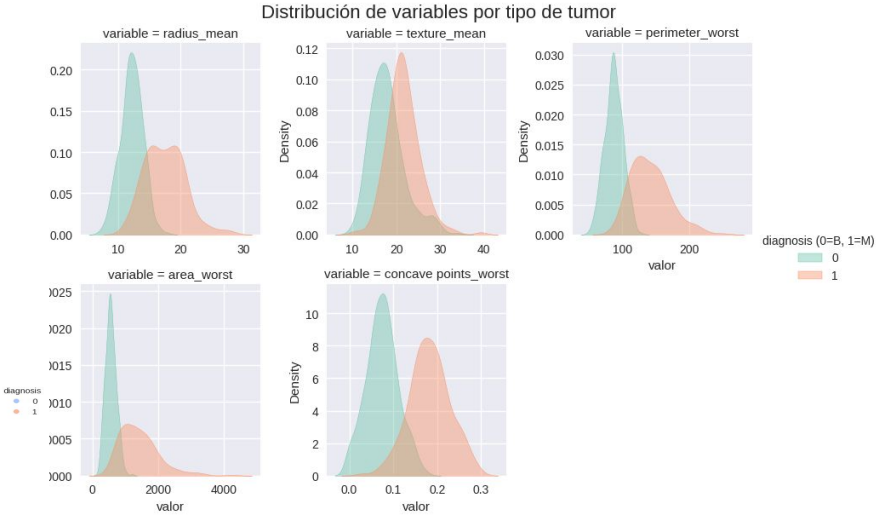
MULTICOLINEALIDAD
radius/perimeter/area (correlación > 0.9)



2. METODOLOGÍA

Separación Causal Casi Lineal

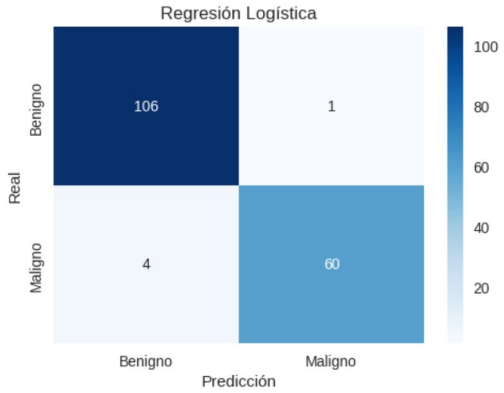


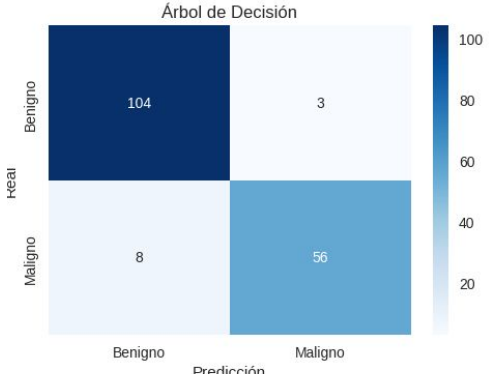


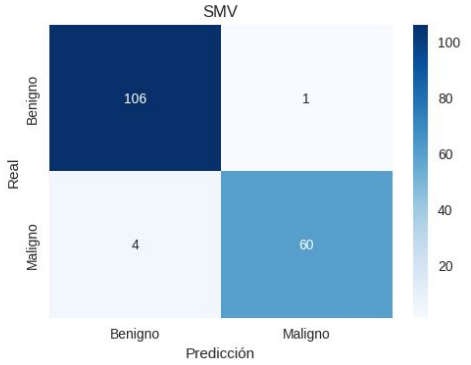
Distribuciones Asimétricas y Disparidad de Escalas. Solución: StandardScaler.

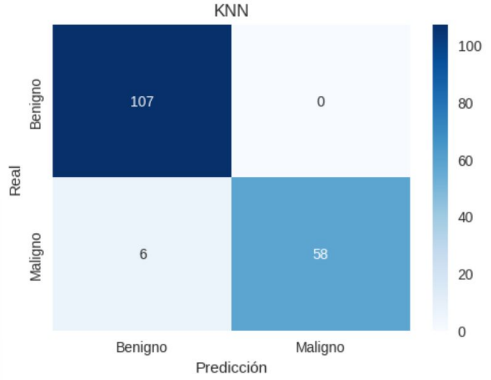
3. RESULTADOS

	Modelo	Accuracy_CV	Accuracy_Test	AUC
0	Regresión Logística	0.974810	0.970760	0.997518
1	SMV	0.974747	0.970760	0.995473
2	KNN	0.969778	0.964912	0.998832
3	Árbol de Decisión	0.942120	0.941520	0.928154

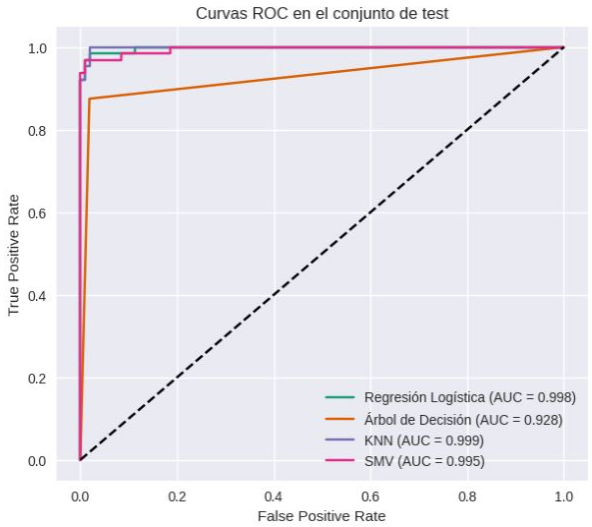


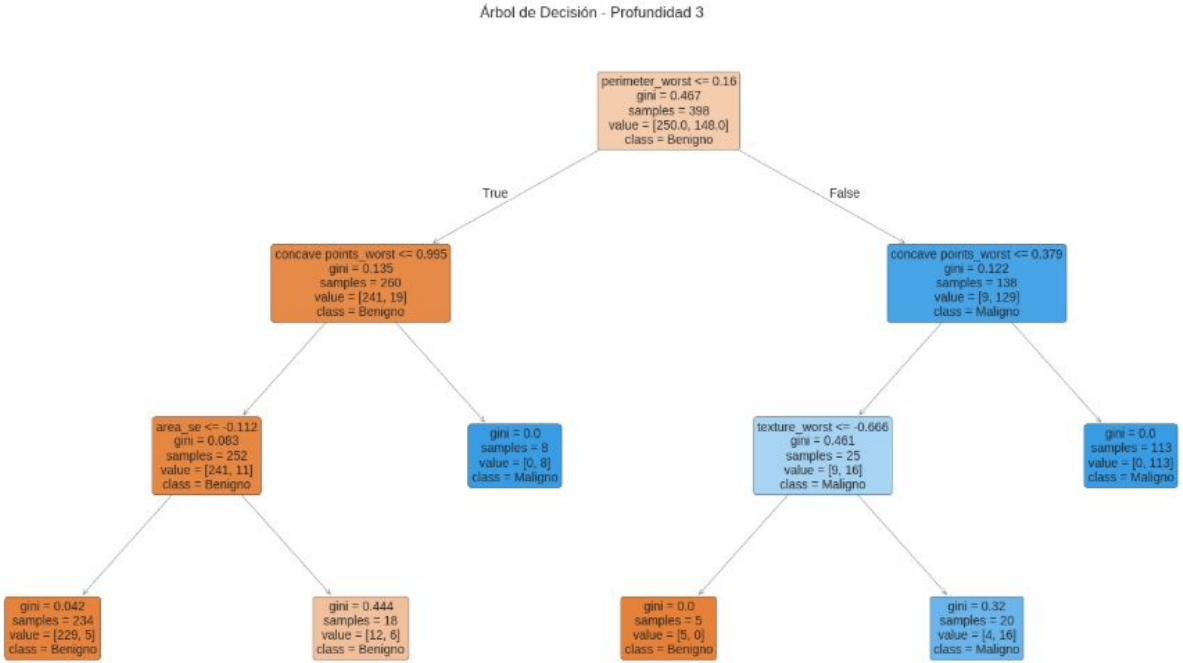






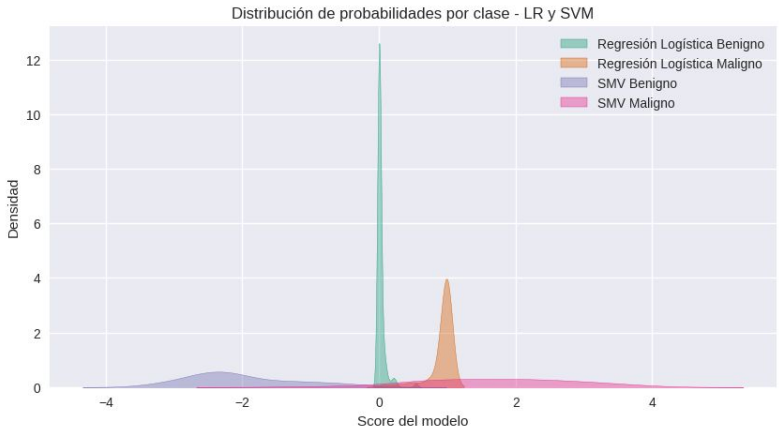
3. RESULTADOS





4. DISCUSIÓN

- **RL** - Destaca por su estabilidad, rendimiento alto y consistente tanto en validación cruzada como en test. Mejor modelo calibrado → frontera casi lineal.
- **SVM** - Maximiza el margen usando el Kernel RBF. Solo clasificar, no para predecir probabilidades.
- **K-NN** - Depende de la estructura de los datos, no es fiable.
- **Árbol de decisión** - Tiende a sobreajuste pero interpreta qué variables son importantes.



RL: sigmoide (0-1)
SVM con kernel RBF C = 10 y gamma =”scale”
K-NN: k = 11 y distancia Manhattan p=1
Árbol de Decisión: max_depht = None

5. CONCLUSIONES

SEPARABILIDAD DEL DATASET



- Variables morfológicas → **clases muy separables**
- Favorece → **modelos lineales / margen.**

MODELOS GANADORES

- **RL & SVM → 97.08% · mínimos FN**
- **KNN → alto rendimiento · sensible solapamiento**
- **Árbol → inestable · sobreajuste**



VALOR DEL TRABAJO



- Pipeline completo → **limpieza · EDA · preprocesado · CV · evaluación**
- Resultado → **modelos fiables para apoyo clínico**

MUCHAS GRACIAS